

AU-DELÀ DES LANGAGES RÉGULIERS

À la fin de ce chapitre, je sais :

- ☞ expliquer les limites des langages réguliers
- ☞ montrer qu'un langage n'est pas régulier

A Limites des expressions régulières

Les langages réguliers permettent de reconnaître un motif dans un texte. Néanmoins, ils ne permettent pas de mettre un sens sur le motif reconnu : celui-ci est reconnu par l'automate mais en quoi est-il différent d'un autre mot reconnu par cet automate ? Par exemple, on peut reconnaître les mots qui se terminent par *tion* mais on ne saura pas faire la différence sémantique entre *révolution* et *abstention*.

Un autre exemple classique est l'interprétation des expressions arithmétiques : comment comprendre que $a \times b - c$ se calcule $(a \times b) - c$ et pas $a \times (b - c)$. Les deux motifs sont des expressions arithmétiques valides mais elles ne s'interprètent pas de la même manière. C'est là une des limites des langages réguliers : une fois le motif reconnu, on ne peut pas l'interpréter. Pour la dépasser, il faut utiliser les notions de grammaires --> HORS PROGRAMME .

Une autre question se pose : comment savoir si un langage est régulier sans pour autant exhiber un automate ? Comment caractériser formellement un langage régulier ?

B Caractériser un langage régulier

R Si un langage est de cardinal fini, alors il est régulier. En effet, chaque mot du langage peut être décrit par une expression rationnelle composée des symboles mêmes des mots. On peut alors construire l'automate qui reconnaît ce langage par la méthode compositionnelle (construction de Thompson). La question de la caractérisation d'un langage régulier concerne donc celle d'un langage de cardinal **infini**.

Théorème 1 — Lemme de l'étoile. Pour tout langage **régulier** \mathcal{L} sur un alphabet Σ , on a :

$$\exists n \geq 1, \forall w \in \mathcal{L}, |w| \geq n \Rightarrow \exists x, y, z \in \Sigma^*, w = xyz \wedge (y \neq \epsilon \wedge |xy| \leq n \wedge \mathcal{L}_{ER}(xy^*z) \subseteq \mathcal{L}) \quad (1)$$

Démonstration. Soit \mathcal{L} un langage régulier sur un alphabet Σ . D'après le théorème de Kleene, il existe un automate fini \mathcal{A} à n états qui reconnaît \mathcal{L} . Soit w un mot reconnu par l'automate \mathcal{A} à n états de longueur m . Il existe un chemin dans \mathcal{A} qui part de l'état initial q_0 et s'achève sur un état accepteur q_m .

$$q_0 \xrightarrow{a_1} q_1 \xrightarrow{a_2} \dots \xrightarrow{a_m} q_m$$

Le chemin contient $m + 1$ états (q_0, \dots, q_m). Puisque $|w| \geq n$, on a $m \geq n$, donc $m + 1 > n$. D'après le principe des tiroirs, le chemin passe forcément deux fois par le même état.

Prenons le premier état par lequel le chemin repasse et notons le i . Il existe donc deux entiers i et j tels que $0 < i < j \leq n < m$ et $q_i = q_j$, c'est-à-dire il existe un cycle de longueur $j - i$ sur le chemin. Comme il s'agit du premier état par lequel on repasse, les états q_0 jusqu'à q_{j-1} sont tous distincts.

On choisit alors de poser $x = a_1 \dots a_{i-1}$, $y = a_i \dots a_{j-1}$ et $z = a_j \dots a_m$. On remarque que $w = xyz$ et que x et xy vérifient les propriétés du lemme de l'étoile car y n'est pas vide et $|xy| \leq n$. Il reste à montrer que $xy^*z \subseteq \mathcal{L}$. Comme le chemin reconnaissant y est un cycle (cf. figure 1), on peut le parcourir autant de fois que l'on veut, 0 ou k fois, le mot sera toujours reconnu par l'automate. ■




FIGURE 1 – Illustration du lemme de l'étoile : si le nombre de lettres d'un mot reconnu w est plus grand que le nombre d'états de l'automate n , alors il existe une boucle sur laquelle on peut itérer.

Théorème 2 — Principe des tiroirs. Si $n + 1$ éléments doivent être placés dans n ensembles, alors il existe au moins un ensemble qui contient au moins 2 éléments. Autrement dit, si E et F sont deux ensembles finis tels que $|E| > |F|$, alors il n'existe aucune application injective de E dans F .




FIGURE 2 – Illustration du principe des tiroirs : on ne peut pas ranger les éléments de E dans les tiroirs de F sans en mettre deux dans un tiroir.

R Le lemme de l'étoile est parfois appelé le lemme de l'itération car on peut itérer autant de fois que l'on veut y .

 **Vocabulary 1 — Pumping lemma** ⇔ Lemme de l'étoile

R Il faut remarquer que le lemme de l'étoile peut être vérifié par un langage non régulier : il s'agit d'une condition **nécessaire pour être régulier mais pas suffisante**. C'est pourquoi, la plupart du temps, on utilise le lemme de l'étoile dans sa forme contraposée pour montrer qu'un langage n'est pas régulier : **s'il ne le vérifie pas, il n'est pas régulier**.

C Langage des puissances

■ **Définition 1 — Langage des puissances.** On appelle langage des puissances le langage défini par :

$$\mathcal{L}_p = \{a^n b^n, n \in \mathbb{N}\} \quad (2)$$

Théorème 3 — Le langage des puissances n'est pas régulier.

Démonstration. Par l'absurde en utilisant le lemme de l'étoile.

Supposons que \mathcal{L}_p soit régulier. Alors il vérifie le lemme de l'étoile. Soit \mathcal{A} un automate à n états qui reconnaît \mathcal{L} . Considérons le mot $w = a^n b^n \in \mathcal{L}_p$. On a bien $|w| = 2n \geq n$. On peut donc appliquer le lemme de l'étoile à w .

D'après ce lemme, il existe une décomposition de w en xyz qui vérifie $|xy| \leq n$ et $y \neq \epsilon$. Soit i et j deux entiers naturels tels que $i + j \leq n$ et $j > 0$. Cette décomposition de w est nécessairement de la forme générale $w = a^i a^j a^{n-i-j} b^n = xyz$, avec $x = a^i$, $y = a^j$ et $z = a^{n-i-j} b^n$.

Les conditions du lemme sont vérifiées et il est donc possible d'itérer sur y : un tel mot appartient toujours au langage. Donc le mot $xy^2z = a^i a^{2j} z = a^i a^{2j} a^{n-i-j} b^n$ devrait appartenir à \mathcal{L}_p . Or ce n'est manifestement pas le cas car $i + 2j + n - i - j = n + j > n$ car $j > 0$.

Le mot obtenu est donc $a^{n+j} b^n$ et que comme $j > 0$, le nombre de a ($n+j$) est strictement différent du nombre de b (n), donc le mot n'est pas dans \mathcal{L}_p .

C'est pourquoi \mathcal{L}_p n'est pas un langage régulier. ■

R

Le théorème 3 est un résultat théorique important à connaître car :

- on peut s'en servir pour démontrer la non régularité d'autres langages en utilisant la stabilité de l'intersection pour les langages réguliers.
- la démonstration est canonique, c'est-à-dire typique de l'utilisation du lemme de l'étoile.

D Langages non réguliers et lemme de l'étoile

Le lemme de l'étoile est une condition nécessaire, mais **pas suffisante** pour qu'un langage soit régulier. Un bon contre-exemple est

$$\mathcal{L} = \{a^i b^j c^k, i = 1 \Rightarrow j = k\}$$

\mathcal{L} vérifie le lemme de l'étoile et pourtant n'est pas un langage régulier.

Démonstration. Par l'absurde.

Supposons que \mathcal{L} est régulier. Alors $\mathcal{L} \cap \mathcal{L}_{ER}(ab^*c^*)$ le serait aussi, car l'intersection de deux langages réguliers est un langage régulier. Or, on observe que :

$$\mathcal{L} \cap \mathcal{L}_{ER}(ab^*c^*) = \{ab^n c^n \mid n \geq 0\}$$

c'est-à-dire qu'il s'agit, à une lettre près, du langage des puissances. Or, on a démontré précédemment que celui-ci n'était pas régulier. C'est donc absurde. \mathcal{L} n'est donc pas régulier. ■

Pour comprendre pourquoi ce langage vérifie le lemme de l'étoile, il faut bien lire la définition de \mathcal{L} . Le langage \mathcal{L} contient deux types de mots :

1. les mots *sous surveillance* dans le cas où $i = 1$: si le mot commence par un seul a , alors il doit impérativement avoir autant de b que de c ($j = k$).
2. Les mots *libres*, cas où $i \neq 1$: si le mot commence par 0, 2, 3 ou n'importe quel autre nombre de a , aucune contrainte ne pèse sur la suite (j et k peuvent être quelconques).

Les mots libres sont les mots du langage régulier $\mathcal{L}_{ER}(a^*b^*c^*)$ qui vérifie nécessairement le lemme de l'étoile.

Prenons un mot *sous surveillance*, par exemple $w = ab^n c^n$. Pour satisfaire le lemme de l'étoile, nous devons trouver une partie du mot à itérer¹ pour que le résultat reste dans \mathcal{L} . L'idée

1. on dit aussi pomper

est de choisir de pomper le premier caractère a . Si on itère ce a , par exemple on le transforme en aa ou aaa , le nombre de a devient différent de 1.

Mathématiquement, la prémissse de l'implication ($i = 1$) devient fausse. Or, une implication dont la prémissse est fausse est toujours vraie. Le mot reste donc dans L , peu importe le nombre de b et de c qui suivent.